¿La mañanera fija la agenda de la oposición?

"Quién es quién en las mentiras" y la Cámara de Diputados, 2021–2024

Equipo 1: Diego Méndez, Tania Hernández, Paola Carmona

Corrección metodología · Tópicos de Políticas Públicas II, otoño 2026

Pregunta central. De 2021 a 2024, la mañanera de López Obrador tuvo cada miércoles una sección, "Quién es quién en las mentiras", en la que el gobierno desmentía notas de medios y de políticos. Preguntamos si, cuando la sección trata un tema de política pública, los diputados hablan más de ese tema en las dos sesiones siguientes. Lo medimos por separado para la oposición (PAN, PRI, PRD y MC) y para Morena, y después comparamos los dos. Importa porque a la oposición le toca vigilar al gobierno: si el Ejecutivo influye en de qué habla, también influye en qué se le vigila.

Qué esperamos. Petrocik (1996) propone que cada partido tiene fama de manejar mejor ciertos temas y que sus candidatos los enfatizan en campaña. Si eso aplica a la tribuna, la oposición preferiría sus propios temas a los de la mañanera. Es una extensión nuestra, porque él estudia campañas presidenciales en Estados Unidos. Lovett, Bevan, y Baumgartner (2015) encuentran que los temas del informe anual del presidente de Estados Unidos aumentan después las audiencias de los comités del Congreso, solo si el presidente es popular y sobre todo en los primeros meses, y que en la Cámara de Representantes dura más si la controla su partido. De ahí tomamos que la oposición podría responder y que Morena, partido del Presidente, podría responder más. Ellos no comparan partidos dentro de una misma cámara, y eso es lo que agregamos.

Datos y muestra. Las transcripciones de la mañanera vienen del repositorio NOSTRODATA, y las de la Cámara, de sus versiones estenográficas, que dicen quién habla y en qué parte de la sesión. Usamos las sesiones ordinarias del Pleno de la LXV Legislatura (septiembre de 2021 a abril de 2024). Para cada emisión tomamos las dos sesiones anteriores y las dos posteriores en el mismo periodo ordinario. La sesión de la tarde del mismo miércoles no cuenta como posterior, porque su orden del día se cerró antes de la mañanera (Reglamento, arts. 60 y 65). Quedan 64 emisiones.

Medición de temas (componente predictivo). Un modelo de lenguaje dividirá cada sección en ítems, uno por desmentido, y asignará cada ítem y cada intervención de los diputados a un tema del Comparative Agendas Project o a "sin tema de política". Compararemos un modelo comercial por API y uno abierto, usaremos el que más coincida con nuestra codificación a mano y guardaremos su versión, las instrucciones y cada respuesta. Gilardi, Alizadeh, y Kubli (2023) muestran que ChatGPT clasificó tuits y noticias mejor que trabajadores en línea en la mayoría de sus tareas, pero al asignar tuits a seis temas acertó poco más de 60 %, menos que ellos. Törnberg (2025) muestra que GPT-4 identificó el partido de políticos de 11 países a partir de un solo tuit, y en Estados Unidos, el único caso que comparó con personas, acertó más que codificadores expertos. De los dos tomamos que un modelo puede hacer este trabajo, pero que su acierto depende de la tarea. Por eso, dos de nosotros codificaremos a mano, sin ver la fecha, una muestra al azar de ítems e intervenciones, y mediremos nuestro acuerdo (alfa de Krippendorff, meta de 0.80) y los aciertos del modelo por tema y por bloque.

Pocos temas. Analizaremos entre cinco y ocho temas y todo lo demás irá a un "resto". Un tema entra si la sección lo tocó en al menos ocho emisiones, si lo distinguimos bien de los demás (si dos se confunden, los juntamos) y si los diputados hablan de él. Los elegiremos antes de ver resultados.

Variable dependiente. Y_{ptse} es el porcentaje de sus palabras que el partido p dedicó al tema t en la sesión s, en la ventana de la emisión e. Solo contamos las partes de la sesión donde el grupo elige

de qué hablar (iniciativas, proposiciones, agenda política e intervenciones sobre diversos temas). Usamos porcentaje porque los partidos hablan cantidades muy distintas: 100 palabras son medio punto del discurso de Morena si dijo 20,000, pero diez puntos del PRD si dijo 1,000. Reportaremos dos tipos de ceros. Si un partido no habló en la sesión, no hay porcentaje y la fila sale. Si habló de otra cosa, Y vale cero y la fila se queda.

Estrategia de identificación. Usamos una diferencia en diferencias para cada bloque. Si un miércoles la sección desmiente una nota sobre desabasto de medicamentos, vemos cuánto cambia el porcentaje del discurso de la oposición dedicado a salud entre las sesiones anteriores y las posteriores, y le restamos el cambio en los temas de control. Si pasó de 4 % a 6 % y los temas de control no cambiaron, el efecto es de 2 puntos. Un tema es tocado si la emisión lo tocó y la anterior no. Son de control los que no tocaron la emisión anterior, esta ni la siguiente, y el "resto" cuando ninguna tocó alguno de sus temas. El supuesto es que, sin la emisión, los temas tocados habrían cambiado igual que los de control. La amenaza principal es que la sección escoge notas que ya circulaban y una noticia puede hacer que todos hablen del tema. Eso afectaría el efecto de cada bloque, pero no su resta si mueve igual a los dos: Olden y Møen (2022) muestran que, si dos diferencias en diferencias tienen el mismo sesgo, al restarlas se cancela. Un estudio de eventos estima el cambio sesión por sesión ($k = -2, +1, +2$, con $k = -1$ como referencia): si el tema ya subía antes de la emisión, se verá ahí.

Modelo. Estimamos por mínimos cuadrados ponderados

$$Y_{ptse} = \beta_O \left(\text{Opos}_p \times \text{Toc}_{te} \times \text{Post}_{se}\right) + \beta_M \left(\text{Morena}_p \times \text{Toc}_{te} \times \text{Post}_{se}\right) + \alpha_{pte} + \gamma_{pse} + \varepsilon_{ptse}$$

α_{pte} es lo que el partido suele dedicarle al tema en esa ventana, el "antes". γ_{pse} es lo que cambió para el partido en esa sesión en todos sus temas a la vez, y con él restamos el cambio de los temas de control. ε_{ptse} es lo que no se explica. Opos_p vale 1 para la oposición, Morena_p para Morena, Toc_{te} si la emisión tocó el tema y Post_{se} en las sesiones posteriores. Cada producto vale 1 solo si se cumplen sus tres condiciones, así que β_O es lo que subió la oposición en el tema tocado después de la emisión, por encima de su "antes" y del cambio en sus demás temas, y β_M es lo mismo para Morena. Están en puntos porcentuales: 2 puntos sobre una base de 4 % son 50 % más. Cada fila pesa según las palabras del partido en la sesión, porque quien dijo un solo discurso tiene 0 % o 100 % en cada tema.

Robustez. Para ver si importa que el efecto sume puntos o multiplique el peso del tema, estimamos también un Poisson con la misma Y, efectos fijos y pesos. También estimamos la regresión sin pesos y con temas de control que no excluyen los de la siguiente emisión, porque excluirlos puede inflar el efecto.

Pruebas de hipótesis. Para cada bloque preguntamos si su efecto es distinto de cero, y lo mismo para la diferencia entre los dos ($H_0 : \beta = 0$). Diremos que hay efecto si la probabilidad de ver un resultado así por pura casualidad es menor a 5 %. Al calcular esa probabilidad tomamos en cuenta que los datos de una misma emisión se parecen entre sí y que una misma sesión aparece en varias ventanas. Como tenemos 64 emisiones, un efecto pequeño puede pasar desapercibido, así que un resultado cercano a cero no probará que no hay efecto, solo que no hay uno grande.

Qué aprenderemos. Si β_O y β_M son positivos y parecidos, la mañanera mueve la agenda de toda la Cámara. Si β_M es mayor, responde más el partido del Presidente, como sugiere nuestra lectura de Lovett, Bevan, y Baumgartner (2015). Si β_O es cercano a cero, la oposición se queda en sus temas, como en la extensión de Petrocik (1996). Si los dos son cercanos a cero, la sección no mueve la agenda de nadie, al menos no en un tamaño detectable.

Heterogeneidad. Exploraremos, una a la vez, diferencias por partido de oposición, por blanco del

ítem (un medio o un actor de oposición), antes y después de septiembre de 2023 y en la primera frente a la segunda sesión.

Referencias

Gilardi, Fabrizio, Meysam Alizadeh, y Maël Kubli. 2023. «ChatGPT Outperforms Crowd Workers for Text-Annotation Tasks». *Proceedings of the National Academy of Sciences* 120(30): e2305016120. doi:10.1073/pnas.2305016120.

Lovett, John, Shaun Bevan, y Frank R. Baumgartner. 2015. «Popular Presidents Can Affect Congressional Attention, for a Little While». *Policy Studies Journal* 43(1): 22-43. doi:10.1111/psj.12087.

Olden, Andreas, y Jarle Møen. 2022. «The Triple Difference Estimator». *The Econometrics Journal* 25(3): 531-53. doi:10.1093/ectj/utac010.

Petrocik, John R. 1996. «Issue Ownership in Presidential Elections, with a 1980 Case Study». *American Journal of Political Science* 40(3): 825-50. doi:10.2307/2111797.

Törnberg, Petter. 2025. «Large Language Models Outperform Expert Coders and Supervised Classifiers at Annotating Political Social Media Messages». *Social Science Computer Review* 43(6): 1181-95. doi:10.1177/08944393241286471.

Fuentes de datos y normas. Cámara de Diputados. Versiones estenográficas de las sesiones del Pleno, LXV Legislatura. https://cronica.diputados.gob.mx. · Cámara de Diputados. 2010. Reglamento de la Cámara de Diputados. Diario Oficial de la Federación, 24 de diciembre de 2010 (última reforma DOF 07-05-2025). · Comparative Agendas Project. Master Codebook. https://www.comparativeagendas.net. · NOSTRODATA. 2024. Conferencias matutinas del presidente Andrés Manuel López Obrador. https://github.com/NOSTRODATA/conferencias_matutinas_amlo.

Anexo: decisiones de diseño y su justificación

Decisión	Por qué	Qué descartamos
Un efecto para cada bloque y luego su resta	Si los dos bloques responden igual, se ve en los dos efectos y no queda escondido en una resta que da cero.	Un solo efecto: cuánto más responde la oposición que Morena.
Nivel normal (α) por emisión	Compara cada tema contra su propio "antes" en la misma ventana, que es lo que dice el supuesto. También toma en cuenta que un bloque ya hablara más del tema antes de la emisión.	Nivel normal por semestre.
Entre cinco y ocho temas y un "resto"	Con pocos temas hay menos ceros y el modelo se equivoca menos.	Los 21 temas del Comparative Agendas Project.
Porcentaje en los dos modelos	Los partidos hablan cantidades muy distintas. Así los dos modelos solo difieren en si el efecto suma o multiplica.	Regresión lineal sobre porcentajes y Poisson sobre palabras.
Regresión lineal ponderada como modelo principal	En la simulación preliminar recupera el tamaño del efecto, y el Poisson lo exagera.	Poisson como modelo principal. Queda como robustez.
Intervenciones en lugar de párrafos	La versión estenográfica no marca párrafos.	Párrafos.
La sesión del mismo miércoles no cuenta como posterior	Su orden del día se cerró antes de la mañanera (Reglamento, arts. 60 y 65).	Contarla.
El "resto" es control solo si no se tocó	Si la emisión tocó uno de sus temas, ya no sirve como comparación.	Usarlo siempre como control.
Control sin la siguiente emisión, como robustez	Excluir los temas de la siguiente emisión puede inflar el efecto.	Una sola definición.
Validación a mano antes de clasificar	Un modelo acierta mucho en unas tareas y menos en otras, como se ve al comparar Gilardi, Alizadeh, y Kubli (2023) con Törnberg (2025).	Confiar en el modelo sin revisarlo, o codificar todo a mano.
Comparar dos modelos de lenguaje	Usamos el que más coincida con nuestra codificación a mano.	Escoger uno sin compararlo.
Errores por emisión y por sesión	Una misma sesión aparece en dos o tres ventanas.	Agrupar solo por emisión.
Heterogeneidad exploratoria, una dimensión a la vez	Con 64 emisiones hay pocos datos por grupo.	Muchas interacciones a la vez.